

Introdução

O Aggregation Framework é um recurso muito interessante do MongoDB . Totalmente nativo e escrito em C++ , ele oferece um conjunto de ferramentas para realizar operações muito mais complexas do que as vistas até aqui. Basicamente, as operações de agregação processam dados e retornam resultados calculados. Essas operações podem agrupar valores de múltiplos documentos ou coleções , executar uma variedade de operações nesses dados agrupados e, por fim, retornar um único resultado. O MongoDB fornece três caminhos para executar operações de agregação: aggregation pipeline , map-reduce function e single purpose aggregation methods . Neste módulo, você se aprofundará no aggregation pipeline, o método mais utilizado e recomendado pela MongoDB .

Aggregation Pipeline

O Aggregation Framework foi modelado sob o conceito de processamento de dados por meio de *pipelines* , ou seja, um "funil" . Um *pipeline* contém múltiplos estágios. Os documentos entram nesse "funil" e vão se transformando à medida que vão passando por esses estágios até chegarem ao estágio final, com um resultado "agregado". Veja um exemplo desses estágios no vídeo abaixo.

No exemplo do vídeo, temos a seguinte operação:

Copiar

```
db.orders.aggregate([
  { $match: { status: "A" } },
  { $group: { _id: "$cust_id", total: { $sum: "$amount" } } }
]);
```

Essa operação possui dois estágios:

Primeiro Estágio : O estágio `$match` filtra os documentos pelo campo `status` , e passam para o próximo estágio somente os documentos que têm `status` igual a "A" .

Segundo Estágio : O estágio `$group` agrupa os documentos pelo campo `cust_id` para calcular a soma dos valores do campo `amount` para cada `cust_id` único.

Note que a sintaxe é como a de uma *query* em MQL (*MongoDB Query Language*). O que aparece de novo é justamente o método `aggregate` . Esse método recebe como primeiro parâmetro um *array* de documentos, que nada mais são do que os estágios do *pipeline* . Você pode ter quantos estágios forem necessários dentro do mesmo `aggregate` .

Um estágio do *pipeline* , por mais básico que seja, já consegue fornecer filtros que atuam como *queries* e podem realizar transformações de documentos que modificam a forma de saída do documento no estágio.

Outras operações do *pipeline* fornecem ferramentas para agrupamento e ordenação de documentos por campos específicos, bem como ferramentas para agregar

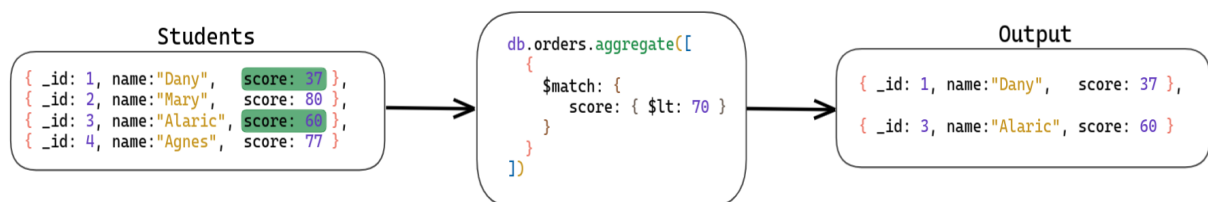
conteúdos de *arrays* (incluindo *arrays* de documentos). Os estágios do *pipeline* podem utilizar **operadores** para tarefas que calculam médias ou concatenam *strings*, por exemplo.

Para melhorar a performance durante os estágios, o aggregation pipeline pode utilizar índices e tem também uma fase interna de otimização.

Agora que você já tem uma boa ideia do que é o aggregation pipeline, vamos explorar alguns de seus estágios para ver todo o seu poder! 😊

Operador \$match

O estágio representado pelo operador **\$match** filtra os documentos da mesma maneira que os filtros no método `find({ $match })`.



É recomendado sempre priorizar o **\$match** o mais "cedo" possível no **pipeline**. Isso melhora muito a performance, uma vez que o **\$match** limita o número de documentos passados para o próximo estágio. E se o **\$match** for utilizado bem no começo do *pipeline*, a *query* tem a vantagem da utilização de índices.

Veja esses documentos na coleção **articles**:

Copiar

```
db.articles.insertMany([
  { _id: ObjectId("512bc95fe835e68f199c8686"), author: "dave", score: 80, views: 100 },
  { _id: ObjectId("512bc962e835e68f199c8687"), author: "dave", score: 85, views: 521 },
  { _id: ObjectId("55f5a192d4bede9ac365b257"), author: "ahn", score: 60, views: 1000 },
  { _id: ObjectId("55f5a192d4bede9ac365b258"), author: "li", score: 55, views: 5000 },
  { _id: ObjectId("55f5a1d3d4bede9ac365b259"), author: "annT", score: 60, views: 50 },
  { _id: ObjectId("55f5a1d3d4bede9ac365b25a"), author: "li", score: 94, views: 999 },
  { _id: ObjectId("55f5a1d3d4bede9ac365b25b"), author: "ty", score: 95, views: 1000 }
])
```

Exemplo 1: Igualdade simples

Vamos fazer uma operação utilizando o operador **\$match** com igualdade simples:

Copiar

```
db.articles.aggregate(  
  [{ $match : { author : "dave" } }]  
);
```

A operação citada seleciona todos os documentos em que o campo **author** seja igual a **dave** . Note que a sintaxe do filtro é exatamente igual à utilizada como filtro no método **find()** . A agregação retornará os seguintes documentos:

Copiar

```
{ _id: ObjectId("512bc95fe835e68f199c8686"), author: "dave", score: 80, views: 100 }  
{ _id: ObjectId("512bc962e835e68f199c8687"), author: "dave", score: 85, views: 521 }  
{ }
```

Exemplo 2: Igualdade complexa

É possível, dentro do **match** , utilizar operadores como **or** , **and** , **in** etc.

Copiar

```
db.articles.aggregate(  
  [  
    {  
      $match: {  
        $or: [  
          { score: { $gt: 70, $lt: 90 } },  
          { views: { $gte: 1000 } }  
        ]  
      }  
    }  
  ]  
);
```

Nessa operação de agregação, o primeiro e único estágio seleciona todos os documentos da coleção **articles** em que o **score** seja maior que **70** e menor que **90** , ou o campo **views** seja maior ou igual a **1000** :

Copiar

```
{ "_id" : ObjectId("512bc95fe835e68f199c8686"), "author" : "dave", "score" : 80, "views" : 100 }  
{ "_id" : ObjectId("512bc962e835e68f199c8687"), "author" : "dave", "score" : 85, "views" : 521 }  
{ "_id" : ObjectId("55f5a192d4bede9ac365b257"), "author" : "ahn", "score" : 60, "views" : 1000 }  
{ "_id" : ObjectId("55f5a192d4bede9ac365b258"), "author" : "li", "score" : 55, "views" : 5000 }
```

```
{ "_id" : ObjectId("55f5a1d3d4bede9ac365b25b"), "author" : "ty", "score" : 95, "views" : 1000 }
```

Operador \$limit

O operador `$limit` limita o número de documentos que será passado para o próximo estágio do pipeline. Ele sempre recebe um valor do tipo inteiro e positivo.

Limitar o número de documentos numa operação de agregação na coleção `articles` é bem simples:

Copiar

```
db.articles.aggregate([
  { $limit : 5 }
]);
```

Essa operação retorna apenas 5 documentos.

Para Fixar

Antes de começar, crie um banco de dados chamado `agg_example` e rode a `query` abaixo para os exercícios.

Copiar

```
use agg_example;
db.transactions.insertMany([
  { value: 5900, from: "Dave America", to: "Ned Flanders", bank: 'International' },
  { value: 1000, from: "Mark Zuck", to: "Edna Krabappel", bank: 'FloridaBank' },
  { value: 209, from: "Lisa Simpson", to: "Dave America", bank: 'bankOfAmerica' },
  { value: 10800, from: "Arnold Schuz", to: "Mark Zuck", bank: 'JPMorgan' },
  { value: 850, from: "Barney Gumble", to: "Lisa Simpson", bank: 'Citigroup' },
  { value: 76000, from: "Ned Flanders", to: "Edna Krabappel", bank: 'JPMorgan' },
  { value: 1280, from: "Dave America", to: "Homer Simpson", bank: 'Citigroup' },
  { value: 7000, from: "Arnold Schuz", to: "Ned Flanders", bank: 'International' },
  { value: 59020, from: "Homer Simpson", to: "Lisa Simpson", bank: 'International' },
  { value: 100, from: "Mark Zuck", to: "Barney Gumble", bank: 'FloridaBank' },
]);
```

Utilizando o banco de dados `agg_example`, faça os seguintes exercícios:

1. Selecione todas as transações feitas pelo cliente chamado "Dave America".
2. Selecione todas as transações com o valor entre 700 e 6000, ou que sejam recebidas pela cliente "Lisa Simpson".
3. Selecione três transações com o valor acima de 1000.

Operador \$project

O operador `$project` tem como uma de suas funções passar adiante no `pipeline` apenas alguns campos dos documentos vindos do estágio anterior, fazendo isso por meio de uma "projeção", como no método `find({}, { $project })`. Mas aqui temos uma diferença: esses campos podem ser novos, sendo resultado de um cálculo ou de uma concatenação.

Assim como numa projeção comum, o único campo que precisa ser negado explicitamente é o `_id`.

Se você especificar um campo que não existe, o `$project` simplesmente ignorará esse campo, sem afetar em nada a projeção.

Veja alguns exemplos, considerando este documento da coleção `books`.

Copiar

```
db.books.insertOne(
  {
    _id: 1,
    title: "A Fundação",
    isbn: "0001122223334",
    author: { last: "Asimov", first: "Isaac" },
    copies: 5
  }
)
```

Exemplo 1: Incluindo campos específicos

Para incluir apenas os campos `_id`, `title` e `author` no documento de saída, utilize o operador `$project` da seguinte maneira:

Copiar

```
db.books.aggregate(
  [
    {
      $project : {
        title : 1,
        author : 1
      }
    }
  ]
);
```

Exemplo 2: Excluindo o campo `_id`

Como você já viu, o campo `_id` é padrão e é o único que necessita de uma negação explícita para que não seja incluído no documento de saída:

Copiar

```
db.books.aggregate([
  {
    $project : {
      _id: 0,
      title : 1,
      author : 1
    }
  }
]);
```

Exemplo 3: Excluindo outros campos

Quando você nega um campo específico, todos os outros serão incluídos no documento de saída. O exemplo abaixo exclui do documento de saída apenas o campo **copies** :

Copiar

```
db.books.aggregate([
  {
    $project : {
      copies: 0
    }
  }
]);
```

Exemplo 4: Excluindo campos em subdocumentos

Para documentos *embedados* , seguimos os mesmos conceitos de *dot notation* :

Copiar

```
db.books.aggregate([
  {
    $project : {
      "author.first": 0,
      copies: 0
    }
  }
]);
```

Para inclusão de campos *embedados* , utilize a mesma lógica, apenas substituindo o 0 por 1 .

Exemplo 5: Incluindo campos calculados

Podemos usar uma **string** iniciada com o caractere **\$** para indicar que queremos projetar um campo, assim: "\$nomeDoCampo".

A operação a seguir adiciona os novos campos **isbn** , **lastname** e **copiesSold** :

Copiar

```
db.books.aggregate([
  {
    $project: {
      title: 1,
      isbn: {
        prefix: { $substr: ["$isbn", 0, 3] },
        group: { $substr: ["$isbn", 3, 2] },
        publisher: { $substr: ["$isbn", 5, 4] },
        title: { $substr: ["$isbn", 9, 3] },
        checkDigit: { $substr: ["$isbn", 12, 1] }
      },
      lastName: "$author.last",
      copiesSold: "$copies"
    }
  }
]);
```

Depois disso, o documento terá o seguinte formato:

Copiar

```
{
  "_id" : 1,
  "title" : "A Fundação",
  "isbn" : {
    "prefix" : "000",
    "group" : "11",
    "publisher" : "2222",
    "title" : "333",
    "checkDigit" : "4"
  },
  "lastName" : "Asimov",
  "copiesSold" : 5
}
```

Lembre-se: esses novos campos são apenas adicionados para a visualização final, não serão salvos no banco.

Operador \$project

O operador **\$project** tem como uma de suas funções passar adiante no **pipeline** apenas alguns campos dos documentos vindos do estágio anterior, fazendo isso por

meio de uma "projeção", como no método `find({}, { $project })` . Mas aqui temos uma diferença: esses campos podem ser novos, sendo resultado de um cálculo ou de uma concatenação.

Assim como numa projeção comum, o único campo que precisa ser negado explicitamente é o `_id` .

Se você especificar um campo que não existe, o `$project` simplesmente ignorará esse campo, sem afetar em nada a projeção.

Veja alguns exemplos, considerando este documento da coleção `books` .

Copiar

```
db.books.insertOne(
{
  _id: 1,
  title: "A Fundação",
  isbn: "0001122223334",
  author: { last: "Asimov", first: "Isaac" },
  copies: 5
}
```

Exemplo 1: Incluindo campos específicos

Para incluir apenas os campos `_id` , `title` e `author` no documento de saída, utilize o operador `$project` da seguinte maneira:

Copiar

```
db.books.aggregate(
[
  {
    $project : {
      title : 1,
      author : 1
    }
  }
]
```

Exemplo 2: Excluindo o campo `_id`

Como você já viu, o campo `_id` é padrão e é o único que necessita de uma negação explícita para que não seja incluído no documento de saída:

Copiar

```
db.books.aggregate([
{
  $project : {
```



```
{
  _id: 0,
  title : 1,
  author : 1
}
];
```

Exemplo 3: Excluindo outros campos

Quando você nega um campo específico, todos os outros serão incluídos no documento de saída. O exemplo abaixo exclui do documento de saída apenas o campo **copies** :

Copiar

```
db.books.aggregate([
{
  $project : {
    copies: 0
  }
}
]);
```

Exemplo 4: Excluindo campos em subdocumentos

Para documentos *embedados* , seguimos os mesmos conceitos de *dot notation* :

Copiar

```
db.books.aggregate([
{
  $project : {
    "author.first": 0,
    copies: 0
  }
}
]);
```

Para inclusão de campos *embedados* , utilize a mesma lógica, apenas substituindo o 0 por 1 .

Exemplo 5: Incluindo campos calculados

Podemos usar uma **string** iniciada com o caractere **\$** para indicar que queremos projetar um campo, assim: "\$nomeDoCampo".

A operação a seguir adiciona os novos campos **isbn** , **lastname** e **copiesSold** :

Copiar

```
db.books.aggregate([
```

```
{
  $project: {
    title: 1,
    isbn: {
      prefix: { $substr: ["$isbn", 0, 3] },
      group: { $substr: ["$isbn", 3, 2] },
      publisher: { $substr: ["$isbn", 5, 4] },
      title: { $substr: ["$isbn", 9, 3] },
      checkDigit: { $substr: ["$isbn", 12, 1] }
    },
    lastName: "$author.last",
    copiesSold: "$copies"
  }
}
];
```

Depois disso, o documento terá o seguinte formato:

Copiar

```
{
  "_id" : 1,
  "title" : "A Fundação",
  "isbn" : {
    "prefix" : "000",
    "group" : "11",
    "publisher" : "2222",
    "title" : "333",
    "checkDigit" : "4"
  },
  "lastName" : "Asimov",
  "copiesSold" : 5
}
```

Lembre-se: esses novos campos são apenas adicionados para a visualização final, não serão salvos no banco.

Operador \$unwind

O operador `$unwind` "desconstrói" um campo *array* do documento de entrada e gera como saída um documento para cada elemento do *array*. Cada documento de saída é o documento de entrada com o valor do campo *array* substituído por um elemento do *array*.

Na prática fica mais fácil de entender. Insira o seguinte documento na coleção `inventory`:

Copiar

```
db.inventory.insertOne({ _id: 7, item: "ABC1", sizes: ["S", "M", "L"] });
```

E agora, utilizando o `$unwind` como um estágio do `pipeline` :

Copiar

```
db.inventory.aggregate([ { $unwind : "$sizes" } ] );
```

O retorno é o seguinte:

Copiar

```
{ "_id" : 7, "item" : "ABC1", "sizes" : "S" }
{ "_id" : 7, "item" : "ABC1", "sizes" : "M" }
{ "_id" : 7, "item" : "ABC1", "sizes" : "L" }
```

Note que temos a "expansão" do `array sizes` , e a saída são três documentos com os valores `_id` e `item` preservados.

Você verá mais exemplos com o operador `$unwind` quando "juntarmos" tudo em vários estágios!

Operador \$lookup

O operador `$lookup` foi introduzido na versão `3.2` do MongoDB e vem evoluindo desde então. Com ele, é possível juntar documentos de outra coleção (`join`). Como resultado dessa junção, um elemento do tipo `array` é adicionado a cada documento da coleção de entrada, contendo os documentos que deram "match" na coleção com a qual se faz o "join".

Existem quatro parâmetros básicos para montar um `$lookup` :

- `from` : uma coleção no mesmo database para executar o `join` ;
- `localField` : o campo da coleção de onde a operação de agregação está sendo executada. Será comparado por igualdade com o campo especificado no parâmetro `foreignField` ;
- `foreignField` : o campo da coleção especificada no parâmetro `from` que será comparado com o campo `localField` por igualdade simples;
- `as` : o nome do novo `array` que será adicionado.

Join com igualdade simples

Considere os seguintes documentos nas coleções `orders` e `inventory` :

Copiar

```
// orders
db.orders.insertMany([
  { _id: 1, item: "almonds", price: 12, quantity: 2 },
  { _id: 2, item: "pecans", price: 20, quantity: 1 },
  { _id: 3 }
])
```

Copiar

```
// inventory
db.inventory.insertMany([
  { _id: 1, sku: "almonds", description: "product 1", instock: 120 },
  { _id: 2, sku: "bread", description: "product 2", instock: 80 },
  { _id: 3, sku: "cashews", description: "product 3", instock: 60 },
  { _id: 4, sku: "pecans", description: "product 4", instock: 70 },
  { _id: 5, sku: null, description: "Incomplete" },
  { _id: 6 }
])
```

Imagine que você queria retornar em uma única *query* os documentos correspondentes das duas coleções mencionadas. A primeira coisa é encontrar um campo em comum entre elas. Nesse caso, seriam os campos *item* (coleção *orders*) e *sku* (coleção *inventory*). Quando cruzados na operação a seguir, um novo campo, chamado *inventory_docs*, será adicionado ao resultado final:

Copiar

```
db.orders.aggregate([
  {
    $lookup: {
      from: "inventory",
      localField: "item",
      foreignField: "sku",
      as: "inventory_docs"
    }
  }
]);
```

Como resultado do *pipeline*, os documentos abaixo serão retornados:

Copiar

```
{
  "_id" : 1,
  "item" : "almonds",
  "price" : 12,
  "quantity" : 2,
  "inventory_docs" : [
    {
      "_id" : 1,
      "sku" : "almonds",
      "description" : "product 1",
      "instock" : 120
    }
  ]
}
```

```

    "_id" : 2,
    "item" : "pecans",
    "price" : 20,
    "quantity" : 1,
    "inventory_docs" : [
      {
        "_id" : 4,
        "sku" : "pecans",
        "description" : "product 4",
        "instock" : 70
      }
    ]
  }
}
{
  "_id" : 3,
  "inventory_docs" : [
    {
      "_id" : 5,
      "sku" : null,
      "description" : "Incomplete"
    },
    {
      "_id" : 6
    }
  ]
}

```

Embora não seja possível realizar uma operação idêntica, uma *query* equivalente em **SQL** seria algo do tipo:

Copiar

```

SELECT * inventory_docs
FROM orders
WHERE inventory_docs IN (
  SELECT *
  FROM inventory
  WHERE sku = orders.item
);

```

Para Fixar

Utilizando o banco de dados **agg_example** , adicione a seguinte **collection** e faça os exercícios:

Copiar

```
use agg_example;
db.clients.insertMany([
  { name: "Dave America", State: "Florida" },
  { name: "Ned Flanders", State: "Alasca" },
  { name: "Mark Zuck", State: "Texas" },
  { name: "Edna Krabappel", State: "Montana" },
  { name: "Arnold Schuz", State: "California" },
  { name: "Lisa Simpson", State: "Florida" },
  { name: "Barney Gumble", State: "Texas" },
  { name: "Homer Simpson", State: "Florida" },
]);
```

1. Selecione todos os clientes com as suas respectivas transações feitas;
2. Selecione quatro clientes com as suas respectivas transações recebidas;
3. Selecione todos os cliente do estado da "Florida" e suas respectivas transações recebidas.

Agora, a prática

Para esta etapa, utilizaremos um *dataset* que contém três coleções: **clientes**, **produtos** e **vendas**. Utilize os comandos abaixo para importar essas coleções para o banco **erp**:

1. Faça o download dos arquivos **json**, clicando com o botão direito e escolhendo a opção "Salvar como":
 - **clientes**
 - **produtos**
 - **vendas**
2. Faça a importação para sua instância do MongoDB:

Copiar

```
mongoimport --db erp <caminho_do_arquivo_clientes.json>
mongoimport --db erp <caminho_do_arquivo_produtos.json>
mongoimport --db erp <caminho_do_arquivo_vendas.json>
```

3. Conecte-se à sua instância e confira o número de documentos em cada coleção:

Copiar

```
use erp;
db.clients.count(); // 499
db.produtos.count(); // 499
db.vendas.count(); // 4900
```

Com o dataset importado, é hora de colocar a mão na massa!

O MongoDB possui diversas ferramentas, como, por exemplo, **mongo** , **mongosh** , **Compass** e outras ferramentas de terceiros. Você pode utilizar o que achar melhor para executar as *queries* , o importante é realizá-las.

Exercício 1: Utilizando o estágio **\$match** , escreva uma agregação para retornar somente os clientes do sexo **"MASCULINO"** .

Exercício 2: Utilizando o estágio **\$match** , escreva uma agregação para retornar somente os clientes do sexo **"FEMININO"** e com data de nascimento entre os anos de **1995** e **2005** .

Exercício 3: Utilizando o estágio **\$match** , escreva uma agregação para retornar somente os clientes do sexo **"FEMININO"** e com data de nascimento entre os anos de **1995** e **2005** , limitando a quantidade de documentos retornados em **5** .

Exercício 4: Conte quantos clientes do estado **SC** existem na coleção. Retorne um documento em que o campo **_id** contenha a UF e outro campo com o total.

Exercício 5: Agrupe os clientes por **sexo** . Retorne o total de clientes de cada sexo no campo **total** .

Exercício 6: Agrupe os clientes por **sexo** e **uf** . Retorne o total de clientes de cada sexo no campo **total** .

Exercício 7 : Utilizando a mesma agregação do exercício anterior, adicione um estágio de projeção para modificar os documentos de saída, de forma que se pareçam com o documento a seguir (não se importe com a ordem dos campos):

Copiar

```
{
  "estado": "SP",
  "sexo": "MASCULINO",
  "total": 100
}
```

Exercício 8 : Descubra quais são os **5** clientes que gastaram o maior valor.

Exercício 9 : Descubra quais são os **10** clientes que gastaram o maior valor no ano de **2019** .

Exercício 10 : Descubra quantos clientes compraram mais de **5** vezes. Retorne um documento que contenha somente o campo **clientes** com o total de clientes.

Dica: O operador **\$count** pode simplificar sua *query* .

Exercício 11 : Descubra quantos clientes compraram menos de três vezes entre os meses de **Janeiro de 2020** e **Março de 2020** .

Exercício 12 : Descubra quais as três **uf** s que mais compraram no ano de **2020** . Retorne os documentos no seguinte formato:

Copiar

```
{
  "totalVendas": 10,
  "uf": "SP"
}
```

Exercício 13 : Encontre qual foi o total de vendas e a média de vendas de cada **uf** no ano de **2019** . Ordene os resultados pelo nome da **uf** . Retorne os documentos no seguinte formato:

Copiar

```
{
```

```
  "_id": "MG",
```

```
  "mediaVendas": 9407.129225352113,
```

```
  "totalVendas": 142
```

```
}
```
